

Algorytmy ewolucyjne

Projekt 3

Tomasz Indeka, 293457

semestr 20L

Oświadczam, że niniejsza praca stanowiąca podstawę do uznania osiągnięcia efektów uczenia się z przedmiotu Algorytmy Ewolucyjne (AE) została wykonana przeze mnie samodzielnie

Tomasz Indeka, 293457

Spis treści

Wstęp	3
Wpływ współczynnika szybkości uczenia się	4
$\eta=0.2$	4
$\eta=0.1$	5
$\eta=0.05$	7
$\eta=0.01$	9
Podsumowanie	14
Wpływ początkowej postaci klasyfikatora	16
Linia pozioma	16
Linia pionowa	17
Linia 45°	18
Linia -45°	19
Podsumowanie	22

1. Wstęp

W ramach projektu należało zaimplementować w MATLABie algorytm uczenia dla liniowego klasyfikatora binarnego w przestrzeni \mathbb{R}^2 . Algorytm uczenia miał być wzorowany na tym opisanym w książce L. Hamela „Knowledge discovery with support vector machines”, w rozdziale 5.1. Algorytm ten był również przedstawiany na wykładach z przedmiotu.

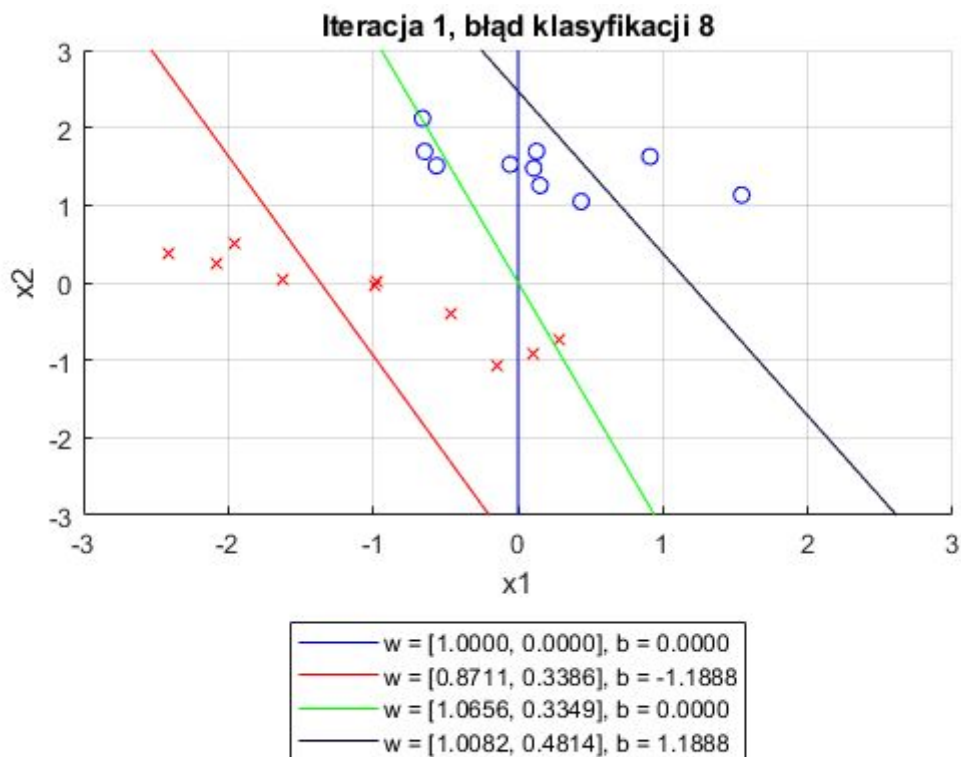
Zbiór treningowy został wygenerowany za pomocą dołączonego skryptu, a dane prezentują się następująco:


x_1	x_2	y
-0.7868	0.6244	1
0.5203	1.4699	1
-0.1576	1.0720	1
-0.2086	0.8296	1
0.4685	0.7218	1
-1.0452	0.9629	1
-0.6125	0.5207	1
-0.0475	0.8837	1
0.1165	0.7259	1
1.3230	1.4301	1
-1.1634	-1.1095	-1
-0.6315	-1.2937	-1
-0.0865	-0.9317	-1
-1.1295	-1.3769	-1
1.2110	-1.3414	-1
1.3391	-1.0778	-1
-0.0705	-0.9817	-1
0.5682	-0.9709	-1
1.3754	-0.8164	-1
-1.4676	-1.4658	-1

2. Wpływ współczynnika szybkości uczenia się

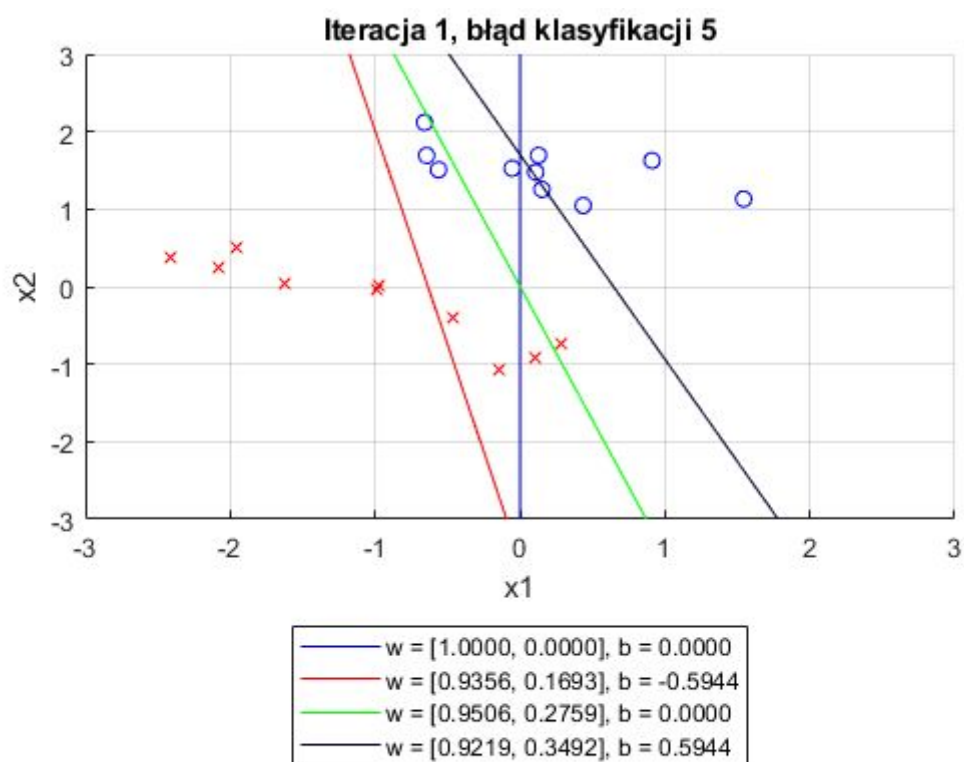
Dla porównania wyników wyznaczonego klasyfikatora w zależności od współczynnika uczenia się wybrałem jako klasyfikator początkowy linię pionową dla wszystkich rozpatrywanych przypadków.


2.1. $\eta = 0.2$



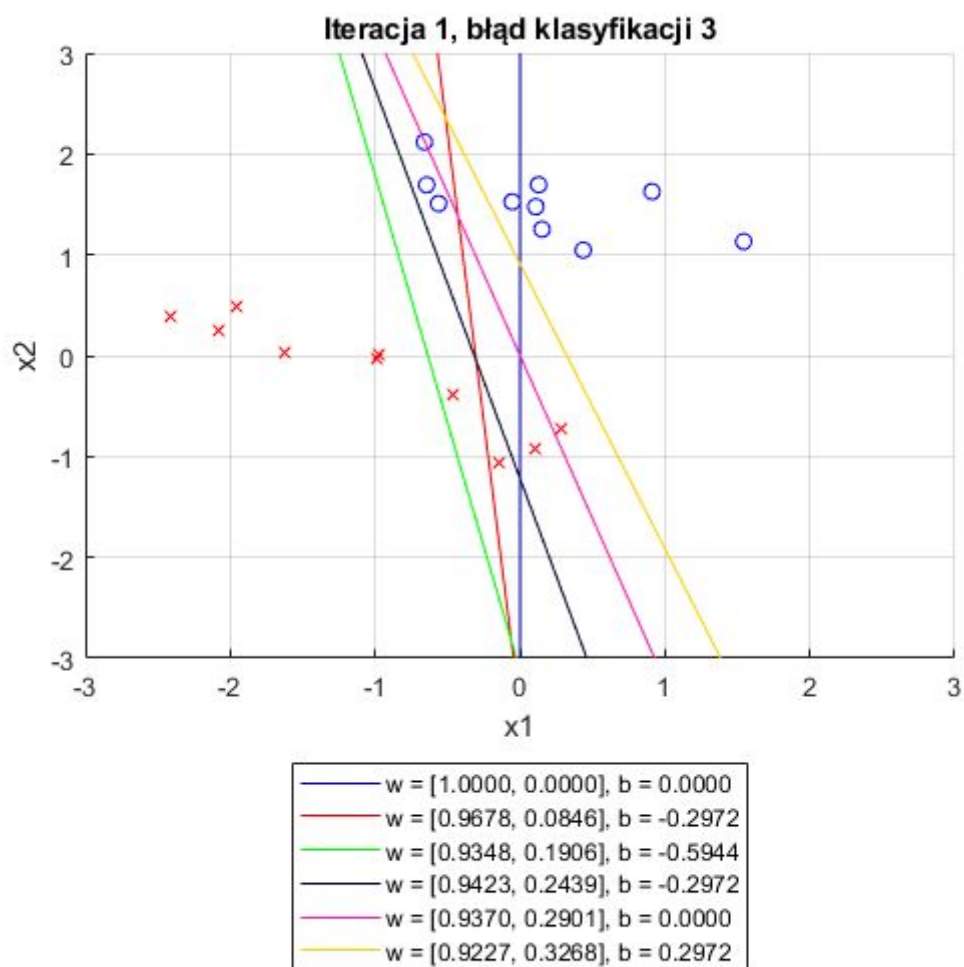



2.2. $\eta = 0.1$






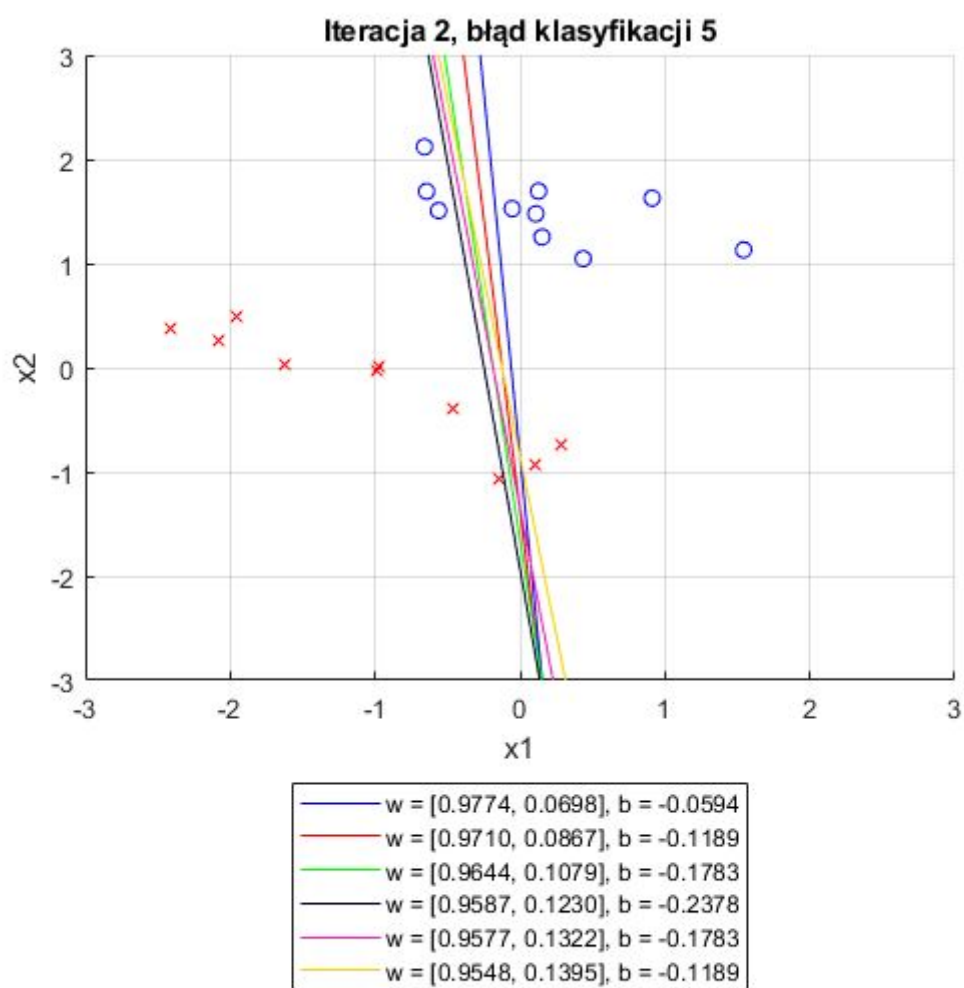
2.3. $\eta = 0.05$








2.4. $\eta = 0.01$






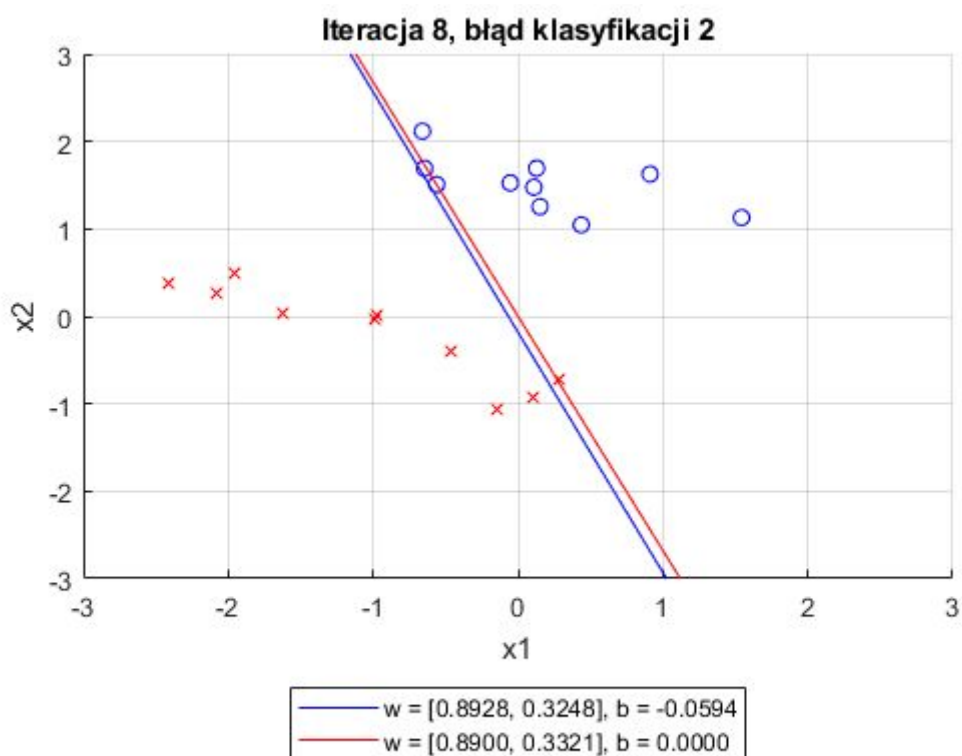




$w = [0.9548, 0.1395], b = -0.1189$
$w = [0.9484, 0.1565], b = -0.1783$
$w = [0.9418, 0.1776], b = -0.2378$
$w = [0.9362, 0.1927], b = -0.2972$
$w = [0.9351, 0.2020], b = -0.2378$
$w = [0.9322, 0.2093], b = -0.1783$







2.5. Podsumowanie

Otrzymane finalne klasyfikatory za pomocą różnych współczynników uczenia się osiągają podane parametry:

Współczynnik uczenia się	$\eta = 0.2$	$\eta = 0.1$	$\eta = 0.05$	$\eta = 0.01$
Parametry klasyfikatora	$w = [0.8793, 0.8200]$ $b = 0.0$	$w = [0.8575, 0.5184]$ $b = 0.0$	$w = [0.8904, 0.4114]$ $b = 0.0$	$w = [0.8806, 0.3564]$ $b = 0.0$
Ilość obliczeń klasyfikatora	5	5	7	27

Jak możemy wywnioskować z powyższej tabeli współczynniki te są dość podobne do siebie, szczególnie patrząc na pierwszy parametr wektora w . Wszystkie otrzymane wyniki przechodzą także przez środek układu współrzędnych.


Na wykresach możemy wyraźnie zauważyć, że im mniejszy współczynnik uczenia się tym to uczenie przebiega wolniej i może potrzebować dużo większej ilości iteracji dla znalezienia optymalnego klasyfikatora. Dodatkowo niskie współczynniki są bardzo nieodporne na ewentualne szumy w prawdziwych danych, ponieważ wyznaczony klasyfikator jest bardzo blisko skrajnych punktów z obu rozdzielanych zbiorów.

Poszukiwanie klasyfikatora stosując większe współczynniki uczenia zapewnia szybsze znajdowanie optymalnego klasyfikatora i jest on zazwyczaj także położony bardziej na środku pomiędzy grupami (nie zbliża się do skrajnych punktów). Niekwestionowanym minusem większych współczynników uczenia się jest jednak bardzo chaotyczne poszukiwanie optimum klasyfikatora.


3. Wpływ początkowej postaci klasyfikatora


Dla porównania znalezionych klasyfikatorów w zależności od klasyfikatora początkowego ustaliłem stały współczynnik szybkości uczenia się dla wszystkich rozpatrywanych przypadków. Wybrałem $\eta = 0.05$, ponieważ jest on kompromisem pomiędzy dość szybkim zbieganiem do zadowalającego klasyfikatora, a odpornością na duże różnice pomiędzy kolejnymi klasyfikatorami

3.1. Linia pozioma




3.2. Linia pionowa




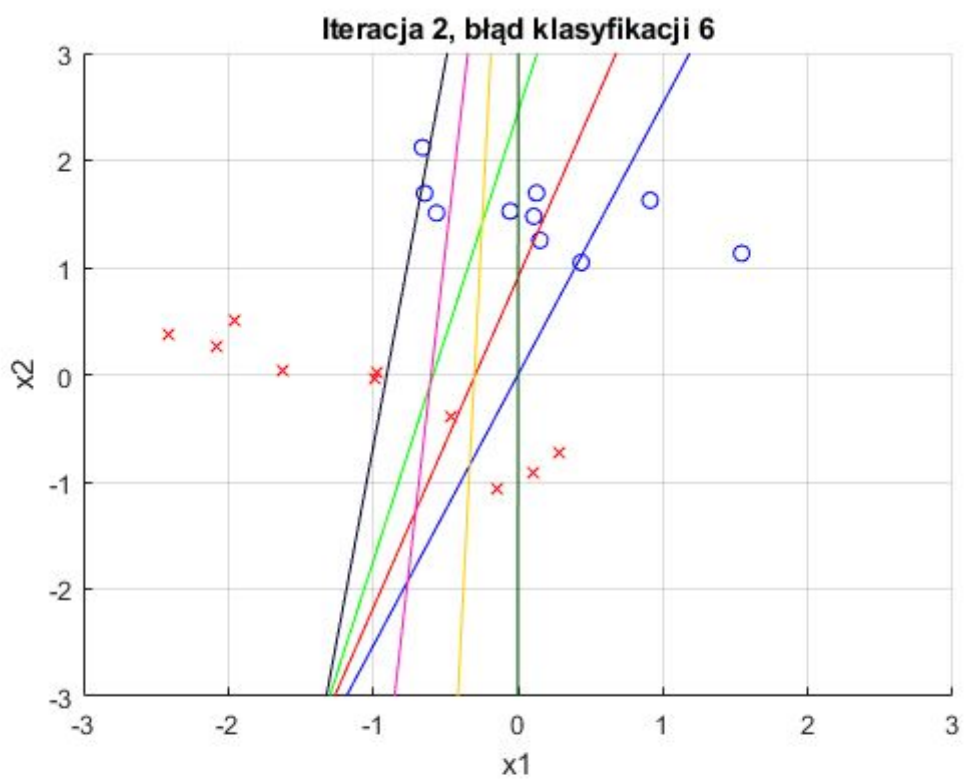


3.3. Linia 45°




3.4. Linia -45°






$w = [1.0436, -0.4122], b = 0.0000$
$w = [1.0113, -0.3275], b = -0.2972$
$w = [1.0177, -0.2428], b = -0.5944$
$w = [0.9848, -0.1369], b = -0.8916$
$w = [0.9923, -0.0836], b = -0.5944$
$w = [0.9870, -0.0373], b = -0.2972$
$w = [0.9726, -0.0007], b = 0.0000$



$w = [0.9726, -0.0007], b = 0.0000$
$w = [0.9404, 0.0839], b = -0.2972$
$w = [0.9074, 0.1899], b = -0.5944$
$w = [0.9149, 0.2432], b = -0.2972$
$w = [0.9096, 0.2894], b = 0.0000$
$w = [0.8953, 0.3260], b = 0.2972$



3.5. Podsumowanie

Otrzymane finalne klasyfikatory przy różnych klasyfikatorach początkowych:

Klasyfikator początkowy	Linia pozioma	Linia pionowa	Linia 45°	Linia -45°
Parametry klasyfikatora	$w = [0.0977, 0.9752]$ $b = 0.2972$	$w = [0.8904, 0.4114]$ $b = 0.0$	$w = [1.0, 1.0]$ $b = 0.0$	$w = [0.8630, 0.4107]$ $b = 0.0$
Ilość obliczeń klasyfikatora	2	7	1	23

Z podanych wyników jednoznacznie widać, że dane dopasowują się bardzo dobrze do linii klasyfikującej o kącie nachylenia 45°. Widać to także bardzo dobrze na przykładzie linii prostopadłej o nachyleniu -45°. Jest ona wyraźnie najgorzej usytuowana względem danych treningowych i poszukiwanie prawidłowo działającego klasyfikatora zajmuje sporo czasu.

Z przedstawionych powyżej wykresów wywnioskować można również, że nie ma najlepszego klasyfikatora początkowego, a szybkość zbiegania zależy przede wszystkim od ułożenia danych testowych.